

Anlık Streaming Yorumlama Projesi Teknik Raporu

1) Raporun Amacı

Bu rapor; mevcut prototipte **ne yapıldığını**, bu çalışmayla **neyin amaçlandığını**, çözümün **nasıl tasarlanıp geliştirildiğini** ve çalışmanın `tubitakozet.pdf` içindeki TÜBİTAK 1005 proje vizyonuna **hangi ölçüde karşılık verdiğini** açıklamak için hazırlanmıştır.

Rapor, depo içindeki şu ana bileşenler incelenerek oluşturulmuştur:

- `server.py`
- `simulator/cloud_simulator.py`
- `simulator/remediation_agent.py`
- `static/index.html`
- `static/app.js`
- `tubitakozet.pdf`

2) Projede Ne Yapıldı?

Mevcut çalışma, tam bir üretim sistemi değil; **AIOps odaklı bir araştırma/prototip platformu** olarak kurgulanmıştır. Çekirdek olarak aşağıdaki yetenekler geliştirilmiştir:

- Kubernetes-benzeri bir ortam için **incident senaryo simülasyonu** oluşturuldu.
- Simüle edilen incident'lerden **alert üretimi** ve metrik zenginleştirme yapıldı.
- Alert'leri analiz eden bir **ReAct tabanlı remediation agent** geliştirildi.
- Agent iki modda çalışacak şekilde tasarlandı:
 - **Rule-Based (simulation)**: bilgi tabanı/runbook üzerinden deterministik çözüm üretir.
 - **LLM-Based (llm)**: harici model API'sinden (Groq/OpenAI) kök neden ve aksiyon üretir.
- Aynı alert için iki modu kıyaslayan bir **compare endpoint**'i ve UI akışı eklendi.
- Üretilen planı simüle eden **remediation execution** ve doğrulama adımları eklendi.
- Tüm bu akışları gösteren bir **FastAPI + web dashboard** (senaryo seçimi, ReAct izleme, plan görüntüleme) hazırlandı.

Özetle: Sistem, "incident oluştuğunda ne oldu, neden oldu, hangi aksiyon önerilmeli, güven skoru ne, alternatif ne?" sorularını uçtan uca gösteren bir **deney ve gösterim altyapısı** sunuyor.

3) Neyi Amaçladık?

Bu prototipin teknik amacı:

- Bulut operasyonlarında manuel müdahaleyi azaltacak bir **otonom olay analiz/iyileştirme yaklaşımını** doğrulamak,
- Rule tabanlı ve LLM tabanlı yaklaşımların **farklarını ölçülebilir hale getirmek**,
- Kök neden analizi ve remediation kararını **açıklanabilir adımlarla (ReAct trace)** göstermek,
- İleri aşamada gerçek cluster, gerçek telemetry ve güvenli otomasyon entegrasyonuna temel hazırlamak.

Araştırma amacı:

- "Önceden tanımlı runbook" yaklaşımı ile "bağlamı yorumlayan model" yaklaşımının güçlü/zayıf yönlerini görmek,
- Bilinmeyen/karmaşık senaryolarda LLM yaklaşımının potansiyelini ortaya koymak,

- Güven skoru ve risk etiketlemesiyle karar kalitesini değerlendirilebilir hale getirmek.

4) Nasıl Yapıldı? (Teknik Mimari ve Akış)

4.1 Mimari Bileşenler

1. API katmanı (`server.py`)

- FastAPI ile uç noktalar tanımlandı.
- Senaryo listeleme, incident tetikleme, remediation çalıştırma, karşılaştırma ve geçmiş erişimi sağlandı.
- Rule ve LLM agent örnekleri aynı servis içinde yönetiliyor.

2. Simülasyon katmanı (`simulator/cloud_simulator.py`)

- 20+ gerçekçi Kubernetes incident senaryosu tanımlandı.
- Senaryolar kategori/severity/pod bilgisi/metrikler/ilişkili servisler/kök neden/optimal fix içeriyor.
- Her tetiklemede metrikler rastgeleleştirilerek (ama gerçekçi aralıkta) varyasyon üretiliyor.
- `kubect1 logs` ve `kubect1 get pods` çıktılarını taklit eden yardımcı simülasyonlar var.

3. Karar katmanı (`simulator/remediation_agent.py`)

- ReAct adımı için veri modeli (`ReActStep`) ve plan modeli (`RemediationPlan`) oluşturuldu.
- Runbook bilgi tabanı üzerinden symptom eşleştirme, tanı adımı, aksiyon seçimi yapılıyor.
- 5 faktörlü güven skor mekanizması (symptom eşleşme, metrik anomali, runbook kapsamı, kanıt zenginliği, aksiyon spesifikliği) eklendi.
- LLM modunda sistem prompt + alert bağlamı + simüle kubectl çıktıları ile JSON plan üretiliyor.
- LLM sonucunda model skoru ile hesaplanan skor harmanlanıyor.
- Bilinmeyen olaylarda "rule-based yetersiz, LLM moda geç" fallback stratejisi var.

4. Arayüz katmanı (`static/index.html` , `static/app.js`)

- Senaryo tetikleme, canlı ReAct adım gösterimi, plan kartları ve confidence breakdown görselleştirildi.
- Rule/LLM/Compare modları arasında geçiş sağlandı.
- Karşılaştırma ekranında süre, güven, adım sayısı ve kök neden benzerliği kıyaslanıyor.
- Remediation uygulama sonrası validasyon çıktısı ve simüle MTTR gösteriliyor.

4.2 Uçtan Uca Çalışma Akışı

1. Kullanıcı bir incident senaryosu seçer veya rastgele incident tetikler.
2. Simülatör alert üretir (dinamik metriklerle).
3. Alert, seçili moda göre remediation agent'a gönderilir.
4. Agent ReAct adımlarıyla kök neden + aksiyon + alternatifler + rollback + validasyon planı üretir.
5. Dashboard bu adımları sıralı gösterir ve güven skorunu görselleştirir.
6. İstenirse plan "execute" edilerek simülasyon sonucu ve doğrulama adımları tamamlanır.

4.3 Teknik Kararların Gerekçesi

- **Simülasyon yaklaşımı:** Gerçek cluster bağımlılığı olmadan hızlı iterasyon ve güvenli demo.
- **Çift mod (Rule + LLM):** Karşılaştırılabilirlik ve araştırma doğrulaması.
- **ReAct trace:** Kararların denetlenebilir ve açıklanabilir olması.
- **Confidence hesaplayıcı:** Tek bir "hissedilen" skor yerine bileşen bazlı ölçüm.

- **Fallback tasarımı:** LLM hatası veya bilinmeyen senaryoda sistemin çalışmayı sürdürmesi.

5) tübitakozet.pdf ile Uyum ve Kapsam Değerlendirmesi

tübitakozet.pdf projesi; 18 aylık, tahminsel ölçekleme + anomali tespiti + kök neden + otomatik düzeltmeyi entegre eden geniş kapsamlı bir AIOps vizyonu tanımlıyor. Mevcut depodaki çalışma bu vizyonun özellikle **olay yönetimi/remediation** kısmına odaklanan bir prototip olarak değerlendirilebilir.

5.1 Hangi Konuda Çalıştık?

Bu depoda en güçlü kapsanan alanlar:

- **Otomatik Anomali Olay Simülasyonu ve Değerlendirme**
- **Kök Neden Analizi (RCA)**
- **Remediation Plan Üretimi**
- **Açıklanabilir karar akışı (ReAct)**
- **Rule tabanlı vs LLM tabanlı yaklaşım karşılaştırması**

5.2 Ne Ölçüde Çalıştık? (Yaklaşık)

Bu oranlar, depo içeriğine dayalı **yaklaşık olgunluk değerlendirmesidir**:

- **Anomali Saptama (gerçek zamanlı üretim değil, senaryo/simülasyon tabanlı): ~%60**
 - Güçlü: Zengin incident kataloğu, metrik/pod/log bağlamı.
 - Eksik: Canlı telemetry pipeline ve gerçek stream analizi.
- **Kök Neden Analizi: ~%70**
 - Güçlü: Senaryo tabanlı RCA, ReAct adımları, LLM ile derin analiz.
 - Eksik: Gerçek üretim log/metric/trace korelasyonu ve dış doğrulama benchmark'ı.
- **Otomatik Olay Düzeltme (self-healing): ~%55**
 - Güçlü: Aksiyon önerisi, rollback/validation, execute simülasyonu.
 - Eksik: Gerçek cluster'da güvenli/izinli otomatik komut çalıştırma ve policy guardrail'leri.
- **Tahminsel Ölçekleme: ~%10-15**
 - Güçlü: Konseptle ilişkili bazı senaryolar (HPA thrashing vb.) mevcut.
 - Eksik: ARIMA/LSTM/Prophet ile 24 saatlik kaynak talep tahmini modülü bu depoda yok.
- **Entegrasyon ve Doğrulama platformu (PoC düzeyi): ~%65**
 - Güçlü: API + UI + simülatör + karar motoru entegre.
 - Eksik: Kubernetes canlı entegrasyonu, performans/başarı KPI test setleri.

5.3 İş Paketi Perspektifi (TÜBİTAK özetiyle eşleme)

- **WP1 Veri Toplama/Ön işleme:** Kısmi (simüle veri üretimi var, gerçek data pipeline yok)
- **WP2 Tahminsel Ölçekleme:** Düşük (henüz temel modül yok)
- **WP3 Otomatik Anomali Saptama:** Orta (senaryo tabanlı)
- **WP4 RCA ve Olay Düzeltme:** Yüksek (prototipin merkezinde)
- **WP5 Entegrasyon/Test:** Orta-yüksek (demo platformu hazır, üretim-validasyon eksik)

Sonuç: Bu proje versiyonu, tübitakozet.pdf vizyonunun özellikle **WP3-WP4-WP5** hattında güçlü bir temel oluşturuyor; **WP2 tahminsel ölçekleme** tarafı ise bir sonraki geliştirme fazı olarak duruyor.

6) Güçlü Yönler

- Incident zenginliği yüksek, farklı domainleri kapsayan senaryo kataloğu.
 - ReAct adım görünürlüğü sayesinde karar süreçleri açıklanabilir.
 - Rule ve LLM modlarının aynı platformda karşılaştırılması araştırma açısından değerli.
 - Güven skoru bileşenlerinin şeffaf verilmesi, karar kalitesini tartışılabilir kılıyor.
 - UI/Backend entegrasyonu demo ve sunum için yeterince olgun.
-

7) Sınırlılıklar

- Çalışma büyük ölçüde simülasyon tabanlı; canlı cluster kanıtı sınırlı.
 - Tahminsel ölçekleme (forecasting modelleri) bu depoda yok/erken aşamada.
 - Güvenlik, izin, denetim (policy-as-code, approval gates) üretim sertliğinde değil.
 - KPI hedefleri (%90 tahmin doğruluğu, 10s tespit vb.) için henüz resmi benchmark seti görünmüyor.
-

8) Sonuç

Mevcut çalışma, "LLM destekli otonom bulut operasyonu" vizyonu için **işlevsel bir PoC** düzeyine ulaşmıştır. Özellikle:

- Anomali olaylarının modellenmesi,
- Kök neden analizi,
- Remediation planlama,
- Explainability (ReAct),
- Rule vs LLM kıyaslaması

alanlarında güçlü bir temel kurulmuştur.

tübitakozet.pdf perspektifinden bakıldığında çalışma, projenin olay yönetimi ayağını anlamlı ölçüde ilerletmiş; ancak tahminsel ölçekleme ve canlı üretim entegrasyonlarında bir sonraki faza ihtiyaç duymaktadır.

9) Önerilen Sonraki Adımlar (Kısa Yol Haritası)

- Gerçek telemetry entegrasyonu (Prometheus, logs, traces) ve canlı veri akışı.
- Tahminsel ölçekleme modülü (ARIMA/LSTM/Prophet) + performans benchmark.
- Güvenli otomasyon katmanı (approval workflow, policy check, blast-radius control).
- Senaryo bazlı regresyon test paketi ve ölçülebilir başarı metrikleri (MTTR, precision/recall, false positive).
- Pilot ortam doğrulaması (staging Kubernetes cluster) ve karşılaştırmalı raporlama.